

Podsetnik sa prošlog predavanja

Detektovanje odstupanja u linearnoj regresiji

- **Izuzetak (outlier)** je tačka iz skupa podataka čiji odgovor y ne prati opšti trend u odnosu na ostatak podataka.
- Tačka podataka ima „**veliku polugu**“ (**high leverage**) ako ima „ekstremne“ vrednosti prediktora x .

Detektovanje odstupanja u opštem slučaju

Izuzeci su ekstremne vrednosti koje odstupaju od ostalih observacija podataka, i oni mogu ukazivati na varijabilnost merenja, eksperimentalne greške ili novinu (eng. novelty). Drugim rečima, odstupanje je zapažanje koje se razlikuje od celokupnog obrasca na uzorku.

Tipovi izuzetaka:

- *Univarijantni*
- *Multivarijantni*

Univarijantna odstupanja se mogu naći kada se gleda distribucija vrednosti u jednom prostoru karakteristika. Multivarijantna odstupanja se mogu naći u n -dimenzionalnom prostoru (od n -karakteristika, n -features). Posmatranje raspodele podataka u n -dimenzionalnim prostorima može biti veoma teško za ljudski mozak, zato moramo da obučimo model koji će to učiniti umesto nas.

Izuzetke takođe možemo podeliti u zavisnosti od okruženja u kojem nastaju: **tačkasti izuzeci**, **kontekstualni izuzeci** ili **kolektivni izuzeci**.

- **Tačkasti izuzeci (Point Anomalies)** - Individualna instanca podataka se smatra anomalijom ako se nalazi isuviše daleko od ostalih podataka. Ovo je najjednostavniji tip anomalija. Pojedinačne tačke podataka leže daleko od ostatka distribucije.
- **Kontekstualna odstupanja (Conditional Anomalies)** - Ova vrsta anomalija je vezana za kontekst i česta je kod vremenskih serija podataka. Na primer, normalno je da ljudi potroše više novca kada je sezona godišnjih odmora, u suprotnom ovakvo ponašanje postaje sumnjivo.

Svaka instanca podataka se definiše na osnovu dva skupa atributa:

- **Kontekstualni atributi** – Koriste se da odrede kontekst (susedstvo) za tu instancu. U prostornim podacima geografska dužina i širina lokacije su kontekstualni atributi.
- **Atributi ponašanja** – Definišu nekontekstualne karakteristike instance. U prostornim podacima ako želimo da opišemo prosečne padavine celog sveta, količina padavina na bilo kojoj lokaciji je atribut ponašanja.

➤ **Kolektivni izuzeci** - kolekcija povezanih instanci podataka se posmatra kao anomalija u odnosu na ceo skup podataka. Individualne instance u toj anomaliji ne moraju biti same anomalije, ali njihova zajednička pojava predstavlja anomaliju. Mogu biti podskup noviteta (*novelties*) u podacima kao što je signal koji može ukazivati na otkrivanje novih pojava.

U procesu proizvodnje, prikupljanja, obrade i analize podataka, odstupanja mogu doći iz mnogih izvora i sakriti se u mnogim dimenzijama. Oni izuzeci koji nisu rezultat greške nazivaju se **novitetima**.

Najčešći uzroci pojavljivanja izuzetaka u skupu podataka:

- *Greške pri unosu podataka* (ljudske greške)
- *Greške merenja* (greške instrumenta)
- *Eksperimentalne greške* (greške u izdvajanju podataka ili planiranju/izvršavanju eksperimenta)
- *Namerno* (lažni izuzeci napravljeni za testiranje metoda za njihovo otkrivanje)
- *Greške u obradi podataka* (manipulacija podacima ili neželjene mutacije skupa podataka)
- *Greške u uzorkovanju* (izdvajanje ili mešanje podataka iz pogrešnih ili različitih izvora)
- *Prirodno* (nije greška, novine u podacima)

Kada pokušavate da otkrijete odstupanja u skupu podataka, veoma je važno imati na umu kontekst i pokušati da se odgovori na pitanje: „*Zašto želim da otkrijem odstupanja?*“ Značenje dobijenih rezultata je diktirano kontekstom koji se posmatra.

Takođe, kada se započinje potraga za otkrivanjem izuzetaka, potrebno je odgovoriti na dva važna pitanja o posmatranom skupu podataka:

1. Koje i koliko karakteristika uzimam u obzir da bih otkrio odstupanja? (univarijantno/multivarijantno)
2. Mogu li da pretpostavim distribuciju vrednosti (raspodelu) za moje izabrane karakteristike? (parametarski/neparametarski)

Oznake podataka

Oznake (eng. label) povezane sa instancama podataka označavaju da li je instanca regularan podatak ili je anomalija. Prikupljanje oznaka se često radi ručno, od strane eksperta, i zbog toga je potrebno puno vremena i novca da bi se prikupile za trening podatke. Obično je teže prikupiti oznake koje pokrivaju sve tipove anomalija nego prikupiti labele za regularne podatke. U nekim slučajevima, kao na primer u saobraćajnoj bezbednosti aviona, prikupljanje anomalija bi ukazalo na katastrofalne događaje. Na osnovu stepena dostupnosti oznaka, tehnike za detekciju anomalija mogu funkcionisati na jedan od sledećih načina:

- **Nadgledana detekcija anomalija** (Supervised Anomaly Detection) – Podrazumeva se dostupnost podataka trening skupa koji ima označene instance i za normalne podatke i za anomalije. Pravi se model za predviđanje za normalne podatke i slučajeve u kojima se javljaju anomalije. Kod nadgledane detekcije anomalija može se naići na jedan od dva problema. Prvi problem nastaje kada anomalija ima mnogo malo u odnosu na normalne instance u trening podacima. Drugi problem je prikupljanje tačnih i reprezentativnih labela, naročito za anomalije.
- **Polunadgledana detekcija anomalija** (Semi-Supervised Anomaly Detection) – Pretpostavlja se da trening podaci imaju označene (*labeled*) instance samo za normalne podatke. Ovaj tip detekcije se puno koristi zato što ne zahteva labele za anomalije. Pravi se model za normalne slučajeve i koristi se da identifikuje anomalije na test podacima.
- **Nenadgledana detekcija anomalija** (Unsupervised Anomaly Detection) – Ova vrsta detekcije ima široku primenu zato što ne zahteva trening podatke. Pravi se implicitna pretpostavka da se normalni podaci znatno češće pojavljuju u testnom skupu od anomalija.

[BLOG Marte Dragičević](#)

Naš fokus u ovom trenutku je na [nenadgledanoj detekciji anomalija](#).

Nenadgledana detekcija anomalija

Pronalaženje anomalija bilo na stream-u ili van mreže (offline) u skupu podataka je presudno za identifikovanje problema u biznisu ili stvaranje proaktivnog rešenja za potencijalno otkrivanje problema pre nego što se dogodi, ili čak u fazi istraživačke analize podataka (Exploratory Data Analysis) za pripremu skupa podataka za ML.

Mnoge aplikacije zahtevaju da imaju tu sposobnost odlučivanja da li nova observacija pripada istoj raspodeli kao i postojeće observacije (*inlier*) ili ga treba smatrati drugačijim (*outlier*). Ova sposobnost se često koristi za čišćenje stvarnih skupova podataka. Moraju se razlikovati dve važne razlike:


- **Detekcija izuzetaka:** Podaci za treniranje modela sadrže izuzetke koji su definisani kao zapažanja koja su daleko od ostalih podataka. Pristupi koji treba da detektuju anomalije pokušavaju da trening podatke uklope u regione u kojima su oni najviše koncentrisani, zanemarujući devijantne observacije.
- **Detekcija noviteta:** Podaci za treniranje nisu „zagađeni“ izuzecima (skup sadrži samo dobre podatke) i mi smo zainteresovani da otkrijemo da li je **nova observacija izuzetak**. U ovom kontekstu, izuzeci se nazivaju novitetima (**novelty**).

Detektovanje izuzetaka i noviteta se koristi za otkrivanje anomalija, tamo gde postoji zainteresovanost za otkrivanje abnormalnih ili neobičnih observacija. Detektovanje izuzetaka je tada poznato i kao *nenadgledano* otkrivanje anomalija, a otkrivanje noviteta kao *polunadgledano* otkrivanje anomalija. U kontekstu otkrivanja izuzetaka, izuzeci/anomalije ne mogu da formiraju gust klaster, jer razvijeni pristupi pretpostavljaju da se izuzeci nalaze u regionima male gustine. Suprotno tome, u kontekstu otkrivanja noviteta, noviteti/anomalije mogu da formiraju gust klaster ako se nalaze u regionu niske gustine podataka za treniranje, koji se u ovom kontekstu smatra normalnim (videti slike na stranicama 9 i 10).

Neke od najpopularnijih metoda za otkrivanje izuzetaka

1. Standardna devijacija

U statistici, ako je raspodela podataka približno normalna, tada oko 68% vrednosti podataka leži unutar jedne standardne devijacije srednje vrednosti i oko 95% je unutar dve standardne devijacije, a oko 99,7% leži unutar tri standardne devijacije.



Prema tome, ako imate bilo koju tačku podataka koja je više od 3 puta veća od standardne devijacije, onda će te tačke vrlo verovatno biti anomalije ili izuzeci.


2. Grubbs' test ([link](#))

Ovo je statistički test koji se uglavnom koristi za otkrivanje odstupanja u univarijantnim skupovima podataka koji pretpostavljaju normalno raspoređenu populaciju. Grubbsov test je definisan kao sledeće dve hipoteze:

H_0 = Ne postoje odstupanja u podacima


H_1 = Postoji najmanje jedno odstupanje u skupu podataka

3. Boxplot



Slika ##. Pet zona box plot.

Boxplot su grafički prikaz numeričkih podataka kroz njihove kvantile. To je vrlo jednostavan, ali efikasan način za vizualizaciju odstupanja.




4. Z-Score ili Extreme Value Analysis (parametarski)

Z-score se može definisati kao pronalaženje odnosa između svake tačke podataka sa standardnom devijacijom i sredinom skupa podataka. Metoda podrazumeva da su podaci u normalnoj raspodeli, što ovu metodu čini parametarskom. Tačke podataka često nisu opisane

pomoću gausove raspodele, pa ovaj problem se može rešiti primenom transformacija na podatke, odnosno: *njihovim skaliranjem*.

$$z = \frac{x - \mu}{\sigma}$$

Z-ocena predstavlja pronalaženje distribucije podataka gde je srednja vrednost 0, a standardna devijacija 1. Dakle, prilikom izračunavanja Z-score vrednosti, podatke treba skalirati i centrirati, a zatim potražite tačke koje su predaleko od nule. Podaci (tačke) koji su daleko od nule tretiraju se kao odstupanja. Obično je izabrani prag 3 ili -3, pa vrednosti veće od 3 ili manje od -3 identifikovane su kao odstupanja.



Z-score je jednostavna, ali moćna metoda za uklanjanje izuzetaka u podacima ako se bavite parametarskom raspodelom u prostoru niskih dimenzija.

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^N (x_i - \mu)^2}$$

Z-Score prednosti:

- Veoma je efikasna metoda ako možete opisati vrednosti u prostoru obeležja pomoću gausove raspodele. (Parametarski)
- Implementacija je vrlo jednostavna koristeći biblioteke pandas i scipy.stats.

Z-Score nedostaci:


- Pogodno je samo za upotrebu u prostoru niskih dimenzija, u malim i srednjim skupovima podataka,
- Ne preporučuje se kada se za distribucije ne može pretpostaviti da su parametarske.

Za neparametarski pristup **DBScan** i **Isolation Forests** su dobra rešenja. **Ovo ćemo tek da učimo...!**

U mašinskom učenju i analitici podataka metode klasterizacije su korisni alati koji nam pomažu da bolje vizualizujemo i razumemo podatke. Odnosi između karakteristika, trendova i populacija u skupu podataka mogu se grafički predstaviti metodama klasterizacije kao što je DBScan. Ove metode se mogu primeniti za otkrivanje izuzetaka u **neparametarskim raspodelama** u **više dimenzija**.

5. **Fitting an elliptic envelop** – isto važi pretpostavka da su podaci iz normalne raspodele.
6. **DBScan klasterizacija podataka**
7. **Isolation Forest**
8. **Local Outlier Factor**
9. **Random Cut Forest (RCF)**
10. ...

Paket '*OutlierDetection*' u R-u se može iskoristiti za detektovanje izuzetaka. Evo još nekih metoda za detekciju izuzetaka koje su implementirane u *scikit-learn* biblioteci u Python-u.




Neke od najpopularnijih metoda za otkrivanje noviteta

Posmatrajmo skup od n podataka čije su observacije iz iste raspodele, opisane sa p karakteristika. Sada tom skupu podataka dodajemo još jednu observaciju. **Da li se novo zapažanje toliko razlikuje od ostalih da možemo sumnjati da je regularno** (tj. da li potiče iz iste distribucije)? **Ili naprotiv, da li je toliko slična drugim tačkama da je ne možemo razlikovati od ostalih observacija?** To je pitanje kojim se bave alati i metode za otkrivanje noviteta.


Cilj nekog opšteg pristupa je da nauči grubu, blisku granicu koja ograničava konturu inicijalne raspodele observacija, koja je ucrtana u *embedded-dimenzionalni prostor*. Tada, ako se nove observacije nalaze unutar tog podprostora ograničenog granicama, onda se smatra da potiču iz iste populacije kao početne observacije. U suprotnom, ako leže izvan granice, tada se može reći da su abnormalni sa datim poverenjem u našu procenu.

Najčešće korišćeni algoritmi za detektovanje noviteta:

1. [One-Class SVM](#) – Bernhard Schölkopf et al., 2001.



2. [Local Outlier Factor](#)



Završna reč o anomalijama

Često anomalije koje leže veoma blizu granice mogu ipak biti normalni podaci, kao što i podaci unutar normalnih regiona koji su blizu granice mogu biti anomalije.

Takođe, jedan od problema je što se u mnogim domenima normalno ponašanje podataka menja i trenutni pojam normalnog ne mora biti dovoljno reprezentativan u budućnosti.

Još jedan od problema je da u različitim domenima tačan pojam anomalije nije isti. Na primer, u medicini mala devijacija od normalnog može biti anomalija, dok na berzi se takva devijacija može smatrati normalnim ponašanjem.